AI MASTER CHALLENGE 002 · REDESIGN DE SUPORTE · ARTHUR LEITE

# Os dados atuais não mostram onde o suporte perde tempo. A triagem pode ser automatizada com segurança, começando em modo sombra.

Resposta às três perguntas do Diretor de Operações, com o grau de certeza de cada uma. Tudo é reproduzível por script, e cada conclusão foi revisada por um agente revisor independente que recalculou os números do zero.

## Resposta em 1 minuto

### ONDE ESTAMOS PERDENDO TEMPO?

**Não dá para afirmar com estes dados.** A base de operação é sintética: tempos impossíveis e satisfação aleatória. A "pior" combinação de canal × prioridade × tipo não se distingue do acaso. O 1º gargalo é de **medição**: proponho instrumentar a operação já na semana 0.

### O QUE AUTOMATIZAR COM IA?

**A triagem.** Validada em 9.568 tickets reais: **65,5% roteados sozinhos com 96,4% de acerto**, 23,3% com 2 sugestões ao agente e 11,2% para humano. Ações sensíveis e respostas: sempre humanas.

### MOSTRE QUE FUNCIONA

**Protótipo no ar** (*Triage Copilot*): classifica, explica, aplica a política e sugere resposta. Libera **~1.200 h/ano** de agente no cenário base (faixa: 550 a 2.100 h), a confirmar no piloto.

## 1. Onde estamos perdendo tempo: o primeiro gargalo é de medição

Antes de procurar gargalos, testei se a base de operação (8.469 tickets) consegue mostrá-los. **Não consegue.**

| TESTE | RESULTADO | |
|---|---|---|
| Os "tempos" são tempos? | São carimbos de data e hora numa janela de 27 h. Em **49%** dos tickets fechados, a resolução acontece *antes* da 1ª resposta. | inválido |
| Algo explica a satisfação? | CSAT uniforme de 1 a 5. Canal, prioridade, tipo, produto, tempo e perfil: **nenhum efeito**. Os testes detectariam diferenças de 0,2 ponto. | ruído |
| As variáveis se relacionam? | **0 de 21** pares associados. "Dúvida de cobrança" tem a mesma chance de vir com assunto "hardware" ou "pagamento". | independentes |
| **Onde o fluxo trava?** (80 combinações canal × prioridade × tipo) | A "pior" parece 7,6 h mais lenta que a "melhor", mas o acaso sozinho gera em média 8,1 h de diferença (teste de permutação p = 0,68). As "melhores" têm duração média **negativa**. | ruído |
| O texto é real? | 100% com campo não preenchido (`{product_purchased}`); 16 frases-modelo; resoluções sem sentido. | sintético |

**Por que isso importa:** qualquer "gargalo por canal" ou "driver de satisfação" tirado desta base teria cara de verdade e levaria a decisões erradas. Uma análise automática padrão, feita por IA sem checagem, cairia nessa armadilha.

### O que dá para fazer já: plano de instrumentação (30 dias)

- Carimbos **separados** de criação, 1ª resposta e resolução, para medir durações reais
- **Log de cada mudança de fila**, para medir reroteamento e tempo perdido na fila errada
- Categoria na abertura × na resolução, para medir o erro de triagem atual
- Tempo ativo do agente separado do tempo de espera; CSAT com taxa de resposta

## 2. O que automatizar: a triagem, em três faixas de confiança

Validado com 47.837 tickets reais de TI (treino em 33 mil; teste em 9.568 nunca vistos). Os tickets do Dataset 1, de outro domínio, foram usados para testar as travas que impedem a IA de decidir sobre o que não conhece. Nesta operação, o modelo é retreinado no histórico próprio antes do modo sombra.




**96,4%**
de acerto na faixa automática (margem de 95,9 a 96,8%). Todas as 8 categorias ≥ 95%; Hardware no limite (95,1%)

**91%**
das vezes, a categoria certa está entre as 2 sugeridas ao agente

**34% → 11%**
tickets de outro domínio que iriam para o automático, sem × com as travas. Dos 11,2% que vão a humano, 9,7% são barrados por essas travas

### Por que um modelo treinado no histórico, e não um LLM, para classificar

| ABORDAGEM (MESMA AMOSTRA DE 400 TICKETS) | ACERTO |
|---|---|
| **Classificador simples treinado no histórico da empresa** | **85%** |
| LLM (Gemini) com os 5 tickets mais parecidos do histórico no prompt | 77% |
| Voto dos 5 tickets mais parecidos (sem LLM) | 73% |
| LLM mais forte (Gemini 3.8 flash) com 3 exemplos por categoria (n = 200, cota) | 54% |
| LLM (Gemini flash-lite) com o nome das categorias | 44% |

A diferença entre o modelo simples e o melhor LLM é estatisticamente significativa (p = 0,0003). Teste feito no plano gratuito do Gemini, com texto já pré-processado: um LLM mais forte, com definições das categorias, provavelmente reduziria a distância.

**O ativo é o histórico rotulado, não o modelo.** As categorias seguem convenções internas: "Administrative rights", por exemplo, é na prática instalação de software. O LLM só melhora quando recebe esse histórico, e mesmo assim não supera o modelo simples. O modelo local tem custo praticamente nulo por ticket, responde em milissegundos e não envia dados para fora. O LLM fica onde agrega: **redigir rascunhos** para o agente revisar.

## 3. O que NÃO automatizar: rotear ≠ executar ≠ responder

| SITUAÇÃO | % DOS TICKETS | REGRA |
|---|---|---|
| **Segurança** (phishing, malware) | 0,7% | Fila de Segurança + escalonamento, **sobrepondo o classificador** |
| **Saúde / afastamento** | 2,0% | Só o RH responde; **sem LLM** (dado sensível, LGPD art. 11) |
| **Desligamento** | 2,3% | Revogação de acessos por humano, com checklist |
| **Aprovação financeira** | 10,4% | A IA prepara; a aprovação é humana |
| **Privilégio de acesso** | 13,0% | Concessão com aprovação do gestor e registro |
| **Urgência / indisponibilidade** | 7,7% | Prioridade sobe e o plantão é notificado |

27,7% dos tickets acionam ao menos uma regra. As regras são explícitas, e não baseadas na categoria, porque os temas sensíveis atravessam as categorias: as menções a segurança se dividem entre Hardware (41%), Admin (19%) e Access (17%).

## 4. Como funciona na prática

```
TICKET ENTRA
 ├─ 1. Política ......... segurança → fila Segurança + escalonamento | urgência → plantão | saúde → sem LLM
 ├─ 2. Travas ........... não reconheço o ticket (idioma/assunto novo) → triagem humana
 ├─ 3. Classificador .... confiança alta → AUTOMÁTICO | média → 2 SUGESTÕES | baixa → HUMANO
 └─ 4. Na fila .......... agente vê: palavras-chave + 3 casos parecidos + rascunho (LLM)
                          ação sensível → sempre humano | correção do agente → retreino mensal
```

O protótipo **Triage Copilot** implementa esse fluxo: triagem ao vivo com explicação, uma fila com milhares de tickets reais (sem escolha a dedo), a matriz de confusão, a política e uma calculadora de ROI com premissas ajustáveis.

## 5. Quanto vale e como confirmar

**552 h**
conservador (1,5 min de triagem/ticket hoje) · 0,3 pessoa · R$ 21 mil/ano

**1.218 h**
**base** (3 min/ticket) · 0,7 pessoa · R$ 47 mil/ano

**2.106 h**
otimista (5 min/ticket) · 1,2 pessoa · R$ 81 mil/ano

É **tempo de agente liberado**, não economia de caixa, e ainda não desconta implantação e manutenção. Volume: 30 mil tickets/ano. Custo/hora: R$ 38 (salário + encargos, salario.com.br, out/2026). O resultado depende quase só de uma premissa de fonte fraca (minutos de triagem hoje). **Ficam fora, de propósito:** o tempo de espera do cliente na fila errada (provavelmente o maior ganho), a redução de reroteamento (não demonstrada) e os rascunhos.

### Piloto de 4 semanas

| SEMANA | O QUE | AVANÇA SE |
|---|---|---|
| 0 | Instrumentar (carimbos, log de mudança de fila) | Dados completos |
| 1–2 | Modo sombra: a IA classifica, mas não roteia | Concordância ≥ 95% na faixa automática |
| 3–4 | Automático ligado em 3 categorias estáveis (Purchase, Access, Storage) | Reatribuições não aumentam |
| 5+ | Todas as categorias + sugestões + rascunho | Ganho medido ≥ cenário conservador |

## 6. Limitações

- **Domínio:** o desempenho foi medido em tickets internos de TI, em inglês. Uma operação de suporte ao cliente retreina com o próprio histórico (minutos, sem GPU) e mede de novo.
- **Rótulos:** o Dataset 2 tem ruído estimado de 15 a 25%; parte dos "erros" pode ser rótulo errado.
- **Travas de domínio:** o limiar foi escolhido observando os mesmos tickets de outro domínio usados para avaliá-lo; o resultado (11% passando) tende a ser otimista.
- **Política:** regras por palavra-chave, sensíveis de propósito, com falsos alarmes (custam segundos) e variações que escapam (ex.: "last day" não aciona desligamento).
- **ROI:** premissas de mercado até o piloto substituí-las por medição.

## O que preciso de você

- **Aprovar a instrumentação (semana 0):** carimbos separados de criação, 1ª resposta e resolução, mais o log de mudança de fila. Sem isso, nenhum diagnóstico de gargalo é confiável.
- **Aprovar 4 semanas de piloto:** modo sombra primeiro (a IA classifica sem rotear), depois o automático em 3 categorias. A decisão de escalar sai dos números do piloto, não destas premissas.
- **Indicar quem é dono das regras do "não automatizar"** (Segurança, RH, Financeiro), para validar e manter a política.

Fontes: `01-diagnostico/outputs/auditoria.md` · `modelo_desperdicio.md` · `03-prototipo/benchmark/outputs/benchmark.md` · `motor_final.md` · pareceres do agente juiz em `process-log/revisoes/`.