AI MASTER CHALLENGE 002 · REDESIGN DE SUPORTE · ARTHUR LEITE

Os dados atuais não mostram onde o suporte perde tempo. A triagem pode ser automatizada com travas de segurança, começando em modo sombra.

Resposta às três perguntas do Diretor de Operações, com o grau de certeza de cada uma. Tudo é reproduzível por script, e cada conclusão foi revisada por um agente revisor independente que recalculou os números do zero.

Resposta em 1 minuto

ONDE ESTAMOS PERDENDO TEMPO?

Não dá para afirmar com estes dados. A base de operação é sintética: tempos impossíveis e satisfação aleatória. A "pior" combinação de canal × prioridade × tipo não se distingue do acaso. O 1º gargalo é de **medição**: proponho instrumentar a operação já na semana 0.

O QUE AUTOMATIZAR COM IA?

A triagem. Validada em 9.568 tickets reais: **65,5% roteados sozinhos com 96,4% de acerto**, 23,3% com 2 sugestões ao agente e 11,2% para humano. Ações sensíveis e respostas: sempre humanas.

MOSTRE QUE FUNCIONA

Protótipo no ar (*Triage Copilot*): classifica, explica, aplica a política e sugere resposta. Libera **~1.200 h/ano** de agente no cenário base (faixa: 550 a 2.100 h), a confirmar no piloto.

1. Onde estamos perdendo tempo: o primeiro gargalo é de medição

Antes de procurar gargalos, testei se a base de operação (8.469 tickets) consegue mostrá-los. **Não consegue.**

TESTE	RESULTADO	
Os "tempos" são tempos?	São carimbos de data e hora numa janela de 27 h. Em **49%** dos tickets fechados, a resolução acontece *antes* da 1ª resposta.	inválido
Algo explica a satisfação?	CSAT uniforme de 1 a 5. Canal, prioridade, tipo, produto, tempo e perfil: **nenhum efeito**. Os testes detectariam diferenças de 0,2 ponto.	ruído
As variáveis se relacionam?	**0 de 21** pares associados. "Dúvida de cobrança" tem a mesma chance de vir com assunto "hardware" ou "pagamento".	independentes
Onde o fluxo trava? (80 combinações canal × prioridade × tipo)	A "pior" parece 7,6 h mais lenta que a "melhor", mas o acaso sozinho gera em média 8,1 h de diferença (teste de permutação p = 0,68). As "melhores" têm duração média **negativa**.	ruído
O texto é real?	100% com campo não preenchido (`{product_purchased}`); 16 frases-modelo; resoluções sem sentido.	sintético

Por que isso importa: qualquer "gargalo por canal" ou "driver de satisfação" tirado desta base teria cara de verdade e levaria a decisões erradas. Uma análise automática padrão, feita por IA sem checagem, cairia nessa armadilha.

O que dá para fazer já: plano de instrumentação (semana 0 do piloto)

- Carimbos **separados** de criação, 1ª resposta e resolução, para medir durações reais
- **Log de cada mudança de fila**, para medir reroteamento e tempo perdido na fila errada
- Categoria na abertura × na resolução, para medir o erro de triagem atual
- Tempo ativo do agente separado do tempo de espera; CSAT com taxa de resposta

2. O que automatizar: a triagem, em três faixas de confiança

Validado com 47.837 tickets reais de TI (treino em 33 mil; teste em 9.568 nunca vistos). Os tickets do Dataset 1, de outro domínio, foram usados para testar as travas que impedem a IA de decidir sobre o que não conhece. Nesta operação, o modelo é retreinado no histórico próprio antes do modo sombra.



96,4%

de acerto na faixa automática (margem de 95,9 a 96,8%). As 8 categorias ≥ 95% (estimativa); Hardware no limite (95,1%)

91%

das vezes, a categoria certa está entre as 2 sugeridas ao agente

34% → 11%

tickets de outro domínio que iriam para o automático, sem × com as travas. Dos 11,2% que vão a humano, 9,7% são barrados por essas travas

Por que um modelo treinado no histórico, e não um LLM, para classificar

ABORDAGEM (MESMA AMOSTRA DE 400 TICKETS)	ACERTO
Classificador simples treinado no histórico da empresa	**85%**
LLM (Gemini) com os 5 tickets mais parecidos do histórico no prompt	77%
Voto dos 5 tickets mais parecidos (sem LLM)	76%
LLM mais forte (Gemini 3.8 flash) com 3 exemplos por categoria (n = 200, cota)	54%
LLM (Gemini flash-lite) com o nome das categorias	44%

A diferença entre o modelo simples e o melhor LLM é estatisticamente significativa (p = 0,0003). Teste feito no plano gratuito do Gemini, com texto já pré-processado: um LLM mais forte, com definições das categorias, provavelmente reduziria a distância.

O ativo é o histórico rotulado, não o modelo. As categorias seguem convenções internas: os termos que mais pesam em "Administrative rights", por exemplo, são de instalação de software. O LLM só melhora quando recebe esse histórico, e aí empata com o simples voto dos 5 tickets mais parecidos: quem acerta é o histórico. O modelo local tem custo praticamente nulo por ticket, responde em milissegundos e não envia dados para fora. O LLM fica onde agrega: **redigir rascunhos** para o agente revisar.

3. O que NÃO automatizar: rotear ≠ executar ≠ responder

SITUAÇÃO	% DOS TICKETS	REGRA
Segurança (phishing, malware)	0,7%	Fila de Segurança + escalonamento, **sobrepondo o classificador**
Saúde / afastamento	2,0%	Só o RH responde; **sem LLM** (dado sensível, LGPD art. 11)
Desligamento	2,0%	Revogação de acessos por humano, com checklist
Aprovação financeira	10,4%	A IA prepara; a aprovação é humana
Privilégio de acesso	3,5%	Concessão com aprovação do gestor e registro
Urgência / indisponibilidade	7,7%	Prioridade sobe e o plantão é notificado

23,4% dos tickets acionam ao menos uma regra. As regras são explícitas, e não baseadas na categoria, porque os temas sensíveis atravessam as categorias: as menções a segurança se dividem entre Hardware (41%), Admin (19%) e Access (17%).

4. Como funciona na prática

```
TICKET ENTRA
 ├─ 1. Política ......... segurança → fila Segurança + escalonamento | urgência → plantão | saúde → sem LLM
 ├─ 2. Travas ........... não reconheço o ticket (idioma/assunto novo) → triagem humana
 ├─ 3. Classificador .... confiança alta → AUTOMÁTICO | média → 2 SUGESTÕES | baixa → HUMANO
 └─ 4. Na fila .......... agente vê: palavras-chave + 3 casos parecidos + rascunho (LLM)
                          ação sensível → sempre humano | correção do agente → retreino mensal
```

O protótipo **Triage Copilot** implementa esse fluxo: triagem ao vivo com explicação, uma fila com milhares de tickets reais (sem escolha a dedo), a matriz de confusão, a política e uma calculadora de ROI com premissas ajustáveis.

5. Quanto vale e como confirmar

552 h
conservador (1,5 min de triagem/ticket hoje) · 0,3 pessoa · R$ 21 mil/ano

1.218 h
base (3 min/ticket) · 0,7 pessoa · R$ 47 mil/ano

2.106 h
otimista (5 min/ticket) · 1,2 pessoa · R$ 81 mil/ano

Em base mensal: de 46 a 175 h/mês (base ≈ 101 h/mês ≈ R$ 3,9 mil/mês). **Maior desperdício recuperável mensurável:** o tempo de triagem manual: ~1.500 h/ano no cenário base, das quais a IA libera ~80%. O maior de todos, a espera do cliente na fila errada, só será medido com a instrumentação.

É **tempo de agente liberado**, não economia de caixa, e ainda não desconta implantação e manutenção. Volume: 30 mil tickets/ano. Custo/hora: R$ 38 (salário + encargos, salario.com.br, out/2026). O resultado depende quase só de uma premissa de fonte fraca (minutos de triagem hoje). **Ficam fora, de propósito:** o tempo de espera do cliente na fila errada (provavelmente o maior ganho), a redução de reroteamento (não demonstrada) e os rascunhos.

Piloto de 4 semanas

SEMANA	O QUE	AVANÇA SE
0	Instrumentar (carimbos, log de mudança de fila)	Dados completos
1–2	Modo sombra: a IA classifica, mas não roteia	Concordância ≥ 95% na faixa automática
3–4	Automático ligado em 3 categorias estáveis (Purchase, Access, Storage)	Reatribuições não aumentam
5+	Todas as categorias + sugestões + rascunho	Ganho medido ≥ cenário conservador

6. Limitações

- **Domínio:** o desempenho foi medido em tickets internos de TI, em inglês. Uma operação de suporte ao cliente retreina com o próprio histórico (minutos, sem GPU) e mede de novo.
- **Rótulos:** o Dataset 2 tem ruído estimado de 15 a 25% (amostra de 32 textos: ordem de grandeza); parte dos "erros" pode ser rótulo errado.
- **Travas de domínio:** o limiar foi escolhido observando os mesmos tickets de outro domínio usados para avaliá-lo; o resultado (11% passando) tende a ser otimista.
- **Política:** regras por palavra-chave, sensíveis de propósito, com falsos alarmes (custam segundos) e variações que escapam (ex.: "last day" não aciona desligamento).
- **ROI:** premissas de mercado até o piloto substituí-las por medição.

O que preciso de você

- **Aprovar a instrumentação (semana 0):** carimbos separados de criação, 1ª resposta e resolução, mais o log de mudança de fila. Sem isso, nenhum diagnóstico de gargalo é confiável.
- **Aprovar 4 semanas de piloto:** modo sombra primeiro (a IA classifica sem rotear), depois o automático em 3 categorias. A decisão de escalar sai dos números do piloto, não destas premissas.
- **Indicar quem é dono das regras do "não automatizar"** (Segurança, RH, Financeiro), para validar e manter a política.

Fontes: `01-diagnostico/outputs/auditoria.md` · `modelo_desperdicio.md` · `03-prototipo/benchmark/outputs/benchmark.md` · `motor_final.md` · pareceres do agente juiz em `process-log/revisoes/`.